

城市空气质量观测数据的 概率统计分析与可视化

PM2.5 分布拟合、季节差异检验、多元回归与高污染画像

汇报人： 骨肉相连

2026 年 5 月 26 日

概率论与数理统计课程 Pre 项目 上海交通大学

1. 一、数据结构与统计问题
2. 二、初阶可视化：分布、季节与相关关系
3. 三、统计检验与多元回归
4. 四、高阶可视化：非线性与高污染画像
5. 结论与汇报口径

一、数据结构与统计问题

项目目标：把空气质量数据转化为统计推断证据

样本量

65 天

核心响应变量

PM2.5

解释维度

气象 + 交通 + 季节

分析主线

- 概率分布：PM2.5 是否近似正态，是否存在右尾风险？
- 统计检验：不同季节 PM2.5 水平是否显著不同？
- 回归解释：气象、交通和季节变量的相对贡献如何？
- 风险画像：高污染日对应怎样的变量组合？

分析层级	统计任务	输出形式
描述统计	均值、标准差、分位数、偏度、峰度	总体描述表、季节描述表
概率建模	Shapiro-Wilk、D'Agostino、Anderson-Darling；Normal / Lognormal / Gamma AIC 比较	分布拟合图、AIC 表
差异检验	ANOVA、Welch ANOVA、Kruskal-Wallis、Holm 校正两两比较	季节分布图、校正 p 值热图
相关与回归	Pearson / Spearman；OLS + HC3；VIF 与诊断检验	相关热图、回归森林图、诊断图
高阶探索	交互项模型、随机森林置换重要性、响应面	模型比较、变量重要性、高污染画像

统计策略不是只“画图展示”，而是用分布 - 检验 - 回归 - 诊断 - 非线性探索形成完整证据链。

二、初阶可视化：分布、季节与相关关系

初阶可视化 I: PM2.5 呈明显右偏分布

核心发现

- 均值 49.47, 中位数 39.20, 最大值 154.40。
- Shapiro-Wilk 检验 $p < 0.001$, 不支持正态分布假设。
- Gamma 分布 AIC 最低: 634.87, 优于 Lognormal 和 Normal。
- 课堂汇报应强调“尾部污染风险”, 而不是只报告平均水平。




图 1: PM2.5 经验分布、核密度与候选概率分布拟合。

初阶可视化 II：季节差异具有强烈可视信号




图 2：季节小提琴图、箱线图与均值置信区间。

可视化解释

- 冬季 PM2.5 分布整体右移，高值区间更集中。
- 夏季分布明显更低，提示扩散条件或季节背景差异。
- 该图适合作为差异检验前的直观铺垫。

注意：图形只能形成判断线索，显著性结论需要后续 ANOVA / Welch / Kruskal-Wallis 支撑。

初阶可视化 III：相关矩阵锁定主要方向




图 3：多维变量相关矩阵。

变量	Pearson r	95% CI	p
气温	-0.756	[-0.844, -0.627]	< 0.001
风速	-0.348	[-0.545, -0.113]	0.005
湿度	0.248	[0.004, 0.464]	0.046
交通指数	0.209	[-0.037, 0.431]	0.095

- 气温与 PM2.5 的负相关最强。
- 风速呈稳定负相关，符合污染扩散直觉。
- 交通指数在双变量层面边际不显著，但在多元模型中变得稳定。

初阶可视化 IV: LOWESS 揭示非线性线索

PM2.5 与气象/交通因素的双变量关系 (黑线为 LOWESS)




图 4: PM2.5 与气温、湿度、风速、交通指数的双变量 LOWESS 曲线。曲线用于发现形态，不直接等同因果关系。

初阶可视化 V：季节画像把多变量差异压缩为一张图




图 5：按季节计算的标准化变量画像。

读图要点

- 冬季：PM2.5 显著偏高、气温显著偏低。
- 夏季：PM2.5 偏低，形成对照组。
- 画像图可以服务后续“季节是结构性背景变量”的解释。

三、统计检验与多元回归

季节差异检验：三类检验给出一致结论

检验	统计量	p 值
One-way ANOVA	51.641	< 0.001
Welch ANOVA	42.892	< 0.001
Kruskal-Wallis	39.124	< 0.001

效应量： $\eta^2 = 0.717$, $\omega^2 = 0.700$, 季节因素具有强解释力。




图 6: Holm 校正后的季节两两比较 p 值热图。

主模型设定

$$\text{PM2.5}_i = \beta_0 + \beta_1 \text{Temp}_i + \beta_2 \text{Humidity}_i + \beta_3 \text{Wind}_i + \beta_4 \text{Traffic}_i + \gamma_s \text{Season}_{is} + \varepsilon_i$$

估计方式：OLS + HC3 稳健标准误；目标是解释 PM2.5 条件均值，而非建立长期因果模型。

- 完整加性模型： $R^2 = 0.891$ ，调整 $R^2 = 0.877$ 。
- 冬季虚拟变量是最强正向效应。
- 风速为稳定负向效应；湿度和交通指数为正向效应。




图 7：标准化回归系数与稳健置信区间。

模型比较：季节变量显著提高解释力




图 8：不同模型的解释力、AIC 与样本内误差。

模型	R^2	Adj. R^2	AIC
空模型	0.000	0.000	660.93
气象模型	0.713	0.699	585.76
气象 + 交通	0.745	0.728	580.05
完整加性	0.891	0.877	531.01
加入交互	0.899	0.883	529.65

从 AIC 和调整 R^2 看，交互模型略优；但课程展示中主模型仍以可解释的完整加性模型为核心。

模型诊断：线性模型总体可用，但存在非线性提示

回归模型诊断：稳健推断前的假设检查




图 9：残差分布、QQ 图、拟合值残差与杠杆诊断。

诊断检验	统计量	p 值
Shapiro-Wilk	0.981	0.428
Jarque-Bera	1.139	0.566
Breusch-Pagan	5.230	0.632
White LM	28.658	0.483
Durbin-Watson	1.842	-
Ramsey RESET	6.356	0.015

- 残差正态性与异方差诊断未显示明显问题。
- RESET 显著，提示应补充非线性或交互探索。

四、高阶可视化：非线性与高污染 画像

高阶可视化 I：随机森林作为非线性稳健性检查




图 10：随机森林置换重要性。

与回归结果的关系

- 气温、季节、风速的重要性最高，与相关和回归结论相互印证。
- 该模型用于发现非线性结构，不替代可解释回归。
- 在小样本条件下，机器学习结果应作为辅助证据而非最终因果判断。

高阶可视化 II：高污染日的变量画像




图 11: Top 20% 高污染日与普通日期的变量差异。

高污染阈值与解释

- 高污染日定义：PM2.5 位于样本前 20%。
- 阈值： $74.14 \mu\text{g}/\text{m}^3$ 。
- 高污染日表现为低温、高交通指数、较高湿度与较弱风速组合。

高阶可视化 III：交通 - 风速响应面呈现条件组合风险




图 12：在气象与季节背景下的交通指数 - 风速响应面。

- 风速越低，污染扩散条件越弱。
- 交通指数越高，局部排放压力越强。
- 二者叠加形成更高 PM2.5 风险区。

响应面适合在 Pre 中承担“高阶可视化亮点”：它把单变量解释推进到条件组合解释。

结论与汇报口径

PM2.5 波动不是单一变量决定，而是季节背景、扩散条件与交通活动共同作用的结果。

1. 分布层面：PM2.5 右偏明显，Gamma 拟合优于正态，尾部风险值得强调。
2. 检验层面：季节差异在三类检验中均显著，效应量很大。
3. 回归层面：完整模型调整 $R^2 = 0.877$ ；冬季、风速、湿度和交通指数解释较稳定。
4. 风险层面：低温、高交通、较弱风速构成高污染日的典型画像。

研究限制

- 样本量仅 65 天，适合课程展示与方法演示。
- 数据缺少真实日期、空间站点、排放源和滞后项。
- 回归结果不能直接外推为长期城市治理因果结论。

复现路径

- 原始数据：data/raw/数据集3_ 空气质量.xlsx
- 主脚本：src/01_analysis.py
- 图像：outputs/figures/
- 表格：outputs/tables/
- 本页幻灯片：slides/beamer/

Q & A

感谢聆听 · 敬请指正