

城市空气质量观测数据的概率统计分析与可视化报告

概率论与数理统计课程 Pre 项目

2026-05-26

摘要

本报告基于 65 天城市空气质量观测数据，对 PM2.5 浓度及其气象、人为因素进行描述统计、概率分布拟合、季节差异检验、相关分析、多元回归、模型诊断与探索性非线性检验。结果显示，PM2.5 呈明显右偏分布，Gamma 分布的 AIC 最低；季节差异高度显著，季节解释效应量较大；在多元回归中，风速、湿度、交通指数和冬季虚拟变量对 PM2.5 具有稳健解释力，完整加性模型调整 $R^2 = 0.877$ 。图形输出分为初阶可视化与高阶可视化两类，均采用统一字体、色彩和版式规范，可直接用于课堂展示与仓库公开发布。

1 数据与问题设定

数据来自数据集 3_ 空气质量.xlsx，包含 65 条日度观测。变量包括 PM2.5 浓度、气温、湿度、风速、交通指数与季节分类。核心研究问题为：

- PM2.5 的经验分布是否近似正态，是否存在右尾污染风险？
- 不同季节的 PM2.5 是否存在显著差异？
- 气象因素与人为交通因素对 PM2.5 的相对贡献如何？
- 哪些条件组合下更容易出现高污染日？

2 数据质量与描述统计

数据无缺失值，样本量为 $n = 65$ 。PM2.5 的均值为 $49.47 \mu g/m^3$ ，标准差为 38.76，中位数为 39.20，最大值达到 154.40，显示出右偏与尾部极端值。

表 1: 主要变量描述统计

变量	均值	标准差	最小值	Q1	中位数	Q3	最大值
PM2.5	49.47	38.76	5.00	20.40	39.20	71.20	154.40
气温	16.25	9.23	-10.80	12.60	16.20	22.10	32.50
湿度	57.30	15.29	20.00	46.60	56.90	68.20	89.70
风速	3.67	1.75	0.50	2.30	3.67	4.89	7.78
交通指数	70.34	16.71	40.00	59.00	69.00	79.00	120.00

3 初阶可视化：分布、季节与双变量关系




图 1: 初阶视角一：PM2.5 的边际分布与季节差异。PM2.5 呈右偏；冬季显著高于其他季节。

正态性检验显示 PM2.5 不是理想正态分布：Shapiro-Wilk 检验统计量为 0.901, $p < 0.001$ ；基于 AIC 的分布比较中，Gamma 分布表现最好 (AIC=634.87)，优于对数正态与正态拟合。该结果支持在汇报中强调“平均水平”之外的尾部风险。




图 2: 初阶视角二：气温与 PM2.5 的负相关最强，风速也呈显著负相关；湿度和交通指数呈弱正相关。

表 2: PM2.5 与解释变量的相关检验

变量	Pearson r	95% CI 下限	95% CI 上限	p 值
气温	-0.756	-0.844	-0.627	< 0.001
湿度	0.248	0.004	0.464	0.046
风速	-0.348	-0.545	-0.113	0.005
交通指数	0.209	-0.037	0.431	0.095




图 3: 季节画像：不同季节在各维度上的标准化偏离。冬季 PM2.5 显著偏高，同时气温显著偏低。

4 季节差异的统计检验

为了避免只依赖图形判断，本报告同时采用单因素 ANOVA、Welch ANOVA 与 Kruskal-Wallis 检验。三类检验均支持季节差异显著，说明结论不依赖单一方差齐性或正态性假设。

表 3: 季节差异检验结果

检验	统计量	<i>p</i> 值
单因素 ANOVA	51.641	< 0.001
Welch ANOVA	42.892	< 0.001
Kruskal-Wallis	39.124	< 0.001

季节因子的效应量为 $\eta^2 = 0.717$ 、 $\omega^2 = 0.700$ ，属于强解释效应。两两比较显示，冬季相对春、夏、秋均显著更高；夏季显著低于春季与秋季。




图 4: 季节两两比较的 Holm 校正 p 值热图。颜色越亮表示差异越显著。

5 多元回归模型与统计推断

主模型设定为：

$$\text{PM2.5}_i = \beta_0 + \beta_1 \text{Temp}_i + \beta_2 \text{Humidity}_i + \beta_3 \text{Wind}_i + \beta_4 \text{Traffic}_i + \gamma_s \text{Season}_{is} + \varepsilon_i. \tag{1}$$

使用 HC3 稳健标准误，以降低小样本与潜在异方差对显著性判断的影响。完整加性模型调整 $R^2 = 0.877$ ，说明气象、人为交通与季节变量合计可解释大部分 PM2.5 波动。

表 4: 标准化回归系数（OLS + HC3 稳健标准误）

变量	标准化系数	95% CI 下限	95% CI 上限	p 值
夏 vs 春	-0.352	-0.822	0.117	0.142
秋 vs 春	0.226	-0.063	0.514	0.125
冬 vs 春	1.490	1.124	1.856	< 0.001
气温	-0.225	-0.475	0.025	0.078
湿度	0.098	0.014	0.183	0.023
风速	-0.328	-0.427	-0.229	< 0.001
交通指数	0.187	0.084	0.291	< 0.001




图 5: 高阶视角一：控制季节后，风速负向效应、交通指数正向效应与冬季抬升效应最稳定。

6 模型诊断与稳健性检查

残差 Shapiro-Wilk 检验 $p = 0.428$, Jarque-Bera 检验 $p = 0.566$, 未显示明显非正态残差; Breusch-Pagan 与 White 检验均未发现显著异方差; Durbin-Watson 统计量为 1.842, 未显示强自相关。然而 Ramsey RESET 检验 $p = 0.015$, 提示线性加性结构可能仍有遗漏的非线性或交互项。因此, 本报告进一步加入交互模型与随机森林探索性检验。

回归模型诊断：稳健推断前的假设检查




图 6: 主回归模型诊断。残差形态基本可接受, 但 RESET 检验提示非线性结构值得进一步探索。

表 5: 模型比较结果

模型	R^2	调整 R^2	AIC	样本内 RMSE
空模型	0.000	0.000	660.93	38.46
气象模型	0.713	0.699	585.76	20.60
交通模型	0.044	0.028	660.03	37.62
气象 + 交通	0.745	0.728	580.05	19.42
气象 + 交通 + 季节	0.891	0.877	531.01	12.71
加入交互项	0.899	0.883	529.65	12.20

7 高污染条件识别与非线性探索

将 PM2.5 位于前 20% 的日期定义为高污染日，阈值为 $74.14\mu g/m^3$ 。高污染日平均气温显著更低，交通指数更高，湿度更高，风速略低。其中气温差异最明显：高污染日平均气温比其他日期低 15.53 摄氏度。




图 7: 高阶视角二：低温、高交通指数和较弱风速共同构成更高污染风险的条件组合。

随机森林的探索性结果显示，气温的置换重要性最高，其次为季节与风速。该结果与回归和相关分析相互印证：PM2.5 不是由单一变量决定，而是季节背景、扩散条件和交通活动共同作用的结果。




图 8: 随机森林置换重要性。该图作为非线性稳健性检查，不替代可解释回归模型。

8 结论与汇报建议

- 概率分布层面：**PM2.5 明显右偏，Gamma 分布拟合优于正态分布。汇报时应强调尾部污染风险，而不只报告均值。
- 季节差异层面：**三类检验均显示季节差异显著，且效应量很大。冬季是 PM2.5 的主要高风险季节。
- 回归解释层面：**完整模型调整 $R^2 = 0.877$ 。控制其他变量后，冬季、风速、湿度与交通指数具有稳健解释力；气温在加入季节后显著性下降，说明其部分作用与季节结构重叠。
- 高污染识别层面：**高污染日更可能出现在低温、高交通、较低风速的组合下。该结论适合转化为课堂展示中的“污染风险画像”。
- 方法限制：**样本量仅 65 天，且无真实日期、排放源、空间站点或滞后项信息。因此本报告可支持课程展示中的统计推断，但不宜外推为城市长期空气治理因果结论。

可复现性说明

所有脚本、图形、表格、PPT、TeX 源文件与 PDF 报告均已纳入项目文件夹。主要脚本为 `src/01_analysis.py`。输出图像见 `outputs/figures/`，统计表见 `outputs/tables/`。